

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

ADRIANA SARTURI

MAPEAMENTO DE DADOS PÚBLICOS NO PARANÁ: PERSPECTIVAS
DE GÊNERO NO PLANEJAMENTO URBANO

DOIS VIZINHOS

2026

ADRIANA SARTURI

MAPEAMENTO DE DADOS PÚBLICOS NO PARANÁ: PERSPECTIVAS
DE GÊNERO NO PLANEJAMENTO URBANO

Mapping Public Data in Paraná: Gender Perspectives in Urban Planning

Trabalho de Conclusão de Curso de Graduação
apresentado como requisito parcial para a
obtenção do título de Bacharel em Engenharia
de Software, Universidade Tecnológica Federal
do Paraná (UTFPR).

Orientador(a): Tarlis Tortelli Portela

DOIS VIZINHOS

2026



4.0 Internacional

Esta licença permite remixe, adaptação e criação a partir do trabalho, mesmo para fins comerciais, desde que sejam atribuídos créditos ao(s) autor(es) e que licenciem as novas criações sob termos idênticos. Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

ADRIANA SARTURI

MAPEAMENTO DE DADOS PÚBLICOS NO PARANÁ: PERSPECTIVAS
DE GÊNERO NO PLANEJAMENTO URBANO

Trabalho de Conclusão de Curso de Graduação
apresentado como requisito para obtenção do
título de Bacharel em Engenharia de Software,
Universidade Tecnológica Federal do Paraná
(UTFPR).

Data de aprovação: 30/Junho/2026

Tarlis Tortelli Portela
Doutor
Universidade Tecnológica Federal do Paraná

Rodolfo Adamshuk Silva
Doutor
Universidade Tecnológica Federal do Paraná

Teruo Matos Maruyama
Doutor
Universidade Tecnológica Federal do Paraná

DOIS VIZINHOS

2026

RESUMO

A literatura demonstra que o planejamento urbano brasileiro apresenta limitações significativas quanto à inclusão da perspectiva de gênero, especialmente no que se refere ao acesso à infraestrutura urbana, transporte e serviços essenciais. A ausência de dados desagregados por sexo representa um desafio para o desenvolvimento de análises das desigualdades presentes no espaço urbano. Diante deste contexto, este trabalho analisou a disponibilidade de dados públicos em cidades do estado do Paraná, Brasil, abrangendo diferentes bases e arquivos disponibilizados em portais oficiais, com foco na identificação da presença ou ausência de informações desagregadas por gênero e no potencial desses dados para uso em estudos urbanos. A metodologia adotada envolveu o levantamento desses arquivos por meio de técnicas de *web crawling* e *web scraping*, seguido de análise. Os resultados evidenciaram a escassez de dados abertos com recorte de gênero na amostra coletada, além de barreiras técnicas que limitam o acesso automatizado aos portais governamentais. Como contribuição, o estudo amplia o debate sobre a perspectiva de gênero no planejamento urbano e incentiva a formulação de políticas públicas mais inclusivas, alinhadas às demandas reais da população.

Palavras-chave: ciência de dados; mineração de dados; planejamento urbano; gênero; web crawling.

ABSTRACT

The literature demonstrates that Brazilian urban planning presents significant limitations regarding the inclusion of the gender perspective, particularly in terms of access to urban infrastructure, transportation, and essential services. The absence of sex-disaggregated data represents a challenge for the development of analyses of inequalities present in the urban space. In this context, this study analyzed the availability of public data in cities of the state of Paraná, Brazil, covering different databases and files made available on official portals, with a focus on identifying the presence or absence of gender-disaggregated information and the potential of such data for use in urban studies. The methodology adopted involved the survey of these files through web crawling and web scraping techniques, followed by their analysis. The results revealed the scarcity of open data with a gender focus in the collected sample, as well as technical barriers that limit automated access to governmental portals. As a contribution, the study broadens the debate on the gender perspective in urban planning and encourages the formulation of more inclusive public policies, aligned with the real demands of the population.

Keywords: data science; data mining; urban planning; gender; web crawling.

SUMÁRIO

1	Introdução	4
2	Fundamentação Teórica	6
2.1	Dados Públicos, Transparência e Dados Abertos	6
2.2	Coleta automatizada de dados na Web.....	6
2.2.1	<i>Web Scraping</i>	6
2.2.2	<i>Web Crawling.....</i>	6
3	Trabalhos Relacionados	7
4	Metodologia	8
4.1	Etapa 1: <i>Crawler</i> (Mapeamento)	9
4.2	Etapa 2: <i>Downloader</i> (Extração)	10
4.3	Etapa 3: Analisador (Mineração).....	10
4.4	Etapa 4: Curadoria Qualitativa (Análise Humana).....	10
5	Desenvolvimento	11
5.1	Tecnologias Utilizadas	11
5.2	Execução em Larga Escala e Protocolos Éticos.....	11
5.3	<i>Download</i>, Mineração de Dados e Curadoria Qualitativa.....	12
5.4	Limitações Técnicas	13
6	Resultados e Discussões.....	14
7	Conclusão	17

Mapeamento de Dados Públicos no Paraná: Perspectivas de Gênero no Planejamento Urbano

Adriana Sarturi¹, Tarlis Tortelli Portela¹

¹Universidade Tecnológica Federal do Paraná (UTFPR)
Dois Vizinhos - PR - Brasil

adrianasarturi@alunos.utfpr.edu.br, tarlis@utfpr.edu.br

Abstract. *The literature demonstrates that Brazilian urban planning presents significant limitations regarding the inclusion of the gender perspective, particularly in terms of access to urban infrastructure, transportation, and essential services. The absence of sex-disaggregated data represents a challenge for the development of analyses of inequalities present in the urban space. In this context, this study analyzed the availability of public data in cities of the state of Paraná, Brazil, covering different databases and files made available on official portals, with a focus on identifying the presence or absence of gender-disaggregated information and the potential of such data for use in urban studies. The methodology adopted involved the survey of these files through web crawling and web scraping techniques, followed by their analysis. The results revealed the scarcity of open data with a gender focus in the collected sample, as well as technical barriers that limit automated access to governmental portals. As a contribution, the study broadens the debate on the gender perspective in urban planning and encourages the formulation of more inclusive public policies, aligned with the real demands of the population.*

Resumo. *A literatura demonstra que o planejamento urbano brasileiro apresenta limitações significativas quanto à inclusão da perspectiva de gênero, especialmente no que se refere ao acesso à infraestrutura urbana, transporte e serviços essenciais. A ausência de dados desagregados por sexo representa um desafio para o desenvolvimento de análises das desigualdades presentes no espaço urbano. Diante deste contexto, este trabalho analisou a disponibilidade de dados públicos em cidades do estado do Paraná, Brasil, abrangendo diferentes bases e arquivos disponibilizados em portais oficiais, com foco na identificação da presença ou ausência de informações desagregadas por gênero e no potencial desses dados para uso em estudos urbanos. A metodologia adotada envolveu o levantamento desses arquivos por meio de técnicas de web crawling e web scraping, seguido de análise. Os resultados evidenciaram a escassez de dados abertos com recorte de gênero na amostra coletada, além de barreiras técnicas que limitam o acesso automatizado aos portais governamentais. Como contribuição, o estudo amplia o debate sobre a perspectiva de gênero no planejamento urbano e incentiva a formulação de políticas públicas mais inclusivas, alinhadas às demandas reais da população.*

1. Introdução

O planejamento urbano desempenha papel fundamental na qualidade de vida da população, influenciando o acesso a serviços, transporte e infraestrutura básica. Esse debate conecta-se à noção de direito à cidade [Lefebvre 2004], compreendida como a possibilidade de acesso pleno, democrático e equitativo aos espaços urbanos. No entanto, estudos apontam que a perspectiva

de gênero nas concepções de espaço e desenho urbano no Brasil ainda tem sido negligenciada, o que resulta em desigualdades práticas no uso dos espaços públicos e nos deslocamentos cotidianos [Pereira and Rebelo 2024]. Esse cenário afeta especialmente as mulheres, que frequentemente conciliam trabalho e cuidados familiares, além de precisarem se deslocar sozinhas pelas ruas à noite. Nesse contexto, evidências da literatura brasileira indicam que as mulheres tendem a vivenciar padrões de mobilidade distintos dos homens, com maior dependência do transporte coletivo e dos deslocamentos a pé [Hannas et al. 2024].

Paralelamente, a disponibilização de dados públicos em portais de transparência e sistemas governamentais ampliou as possibilidades de pesquisa em diversas áreas. Contudo, grande parte desses dados não é desagregada por gênero [Freitas and Praça 2024], o que dificulta análises voltadas à equidade de gênero. Essa lacuna reflete o que [Criado Perez 2022] denomina de “viés de gênero nos dados”, isto é, a tendência de que a maioria dos sistemas de dados tenham sido historicamente estruturados com base em um padrão masculino. Essa lógica está diretamente associada à baixa participação feminina nos processos de planejamento urbano, onde a falta de representatividade contribui para que as cidades sejam concebidas sob uma perspectiva predominantemente masculina, resultando em soluções que nem sempre refletem as necessidades de grupos diversos [PNUD et al. 2022]. Em conjunto, esses fatores comprometem o desenvolvimento de estratégias de gestão urbana mais equitativas e limitam o avanço de estudos críticos sobre desigualdades no espaço urbano.

No campo da Engenharia de Software, técnicas de mineração e coleta automatizada de dados têm sido amplamente exploradas para apoiar a extração, organização e análise de informações. Aplicadas ao contexto urbano, essas abordagens permitem identificar padrões, ausência de dados e estruturas de dados públicos, contribuindo para análises baseadas em dados reais do cotidiano da população. De acordo com [Han et al. 2012], a mineração de dados consiste no processo de extração automatizada de padrões e conhecimentos úteis a partir de grandes conjuntos de dados, sendo aplicável a diversas áreas do conhecimento. Nesse sentido, tais técnicas representam uma oportunidade de inovação tecnológica com impacto social, possibilitando a investigação de dados urbanos e de contribuição para a integração da perspectiva de gênero em políticas urbanas.

Diante desse cenário, o presente trabalho tem como objetivo analisar a disponibilidade de dados públicos nos municípios de Curitiba, Londrina e Maringá, os três maiores polos urbanos do estado do Paraná, abrangendo tanto dados diretamente relacionados ao planejamento urbano quanto aqueles com potencial para subsidiá-lo, com foco na presença ou ausência de informações desagregadas por gênero. Além disso, propõe-se discutir a viabilidade de soluções automatizadas para raspagem e análise desses dados. Neste contexto, estabelece-se como objetivo secundário mapear as barreiras técnicas de acessibilidade encontradas durante a coleta automática (como falhas de conexão, links quebrados e a estrutura dos portais). Dessa forma, é possível mapear indicadores das dificuldades de acesso para o nível de transparência dos dados públicos em portais oficiais das prefeituras. Busca-se, com isso, apoiar pesquisas futuras e subsidiar a formulação de políticas públicas mais inclusivas, contribuindo para o diagnóstico da disponibilidade de dados com recorte de gênero na esfera pública.

O artigo está estruturado da seguinte maneira: a Seção 2 apresenta a fundamentação teórica; a Seção 3 detalha os trabalhos relacionados; a Seção 4 descreve a metodologia utilizada; a Seção 5 descreve o processo de desenvolvimento do trabalho, enquanto a Seção 6 apresenta os resultados e discussões referentes à disponibilidade dos dados e à perspectiva de gênero; e, por fim, a Seção 7 conclui o artigo e oferece possíveis caminhos para trabalhos futuros.

2. Fundamentação Teórica

A fundamentação teórica que segue apresenta conceitos que embasam este trabalho. São abordados os temas de dados públicos, transparência e dados abertos, bem como as técnicas automatizadas de coleta de informações na web.

2.1. Dados Públicos, Transparência e Dados Abertos

A disponibilização de dados públicos em portais governamentais ampliou as possibilidades de acesso à informação e o desenvolvimento de pesquisas baseadas em dados oficiais. No Brasil, iniciativas relacionadas à transparência pública e à Lei de Acesso à Informação (Lei nº 12.527/2011) incentivaram a disponibilização de dados e documentos governamentais em meios digitais.

A Lei de Acesso à Informação estabelece que informações produzidas ou armazenadas por órgãos públicos devem ser disponibilizadas à sociedade, salvo em casos de sigilo previstos em legislação [Brasil 2011]. Além disso, ela incentiva mecanismos de transparência ativa, nos quais dados e documentos são publicados espontaneamente em portais eletrônicos oficiais, sem necessidade de solicitação prévia pelos cidadãos.

Nesse contexto, a disponibilização de dados públicos em formatos digitais possibilita sua utilização em análises, aplicações computacionais e estudos relacionados ao contexto urbano.

2.2. Coleta automatizada de dados na Web

A coleta automatizada de dados na Web consiste na utilização de técnicas computacionais para obtenção de informações disponíveis em páginas e sistemas online [Mitchell 2018, Liu and Menczer 2011]. Essas abordagens permitem automatizar tarefas de coleta, organização e armazenamento de dados, especialmente em contextos envolvendo grandes volumes de informações públicas. Entre as principais técnicas utilizadas destacam-se o *web scraping* e o *web crawling*, frequentemente empregados em aplicações voltadas à mineração e análise de dados [Han et al. 2012].

2.2.1. Web Scraping

O *web scraping* corresponde à extração automatizada de informações presentes em páginas web, permitindo identificar e estruturar conteúdos específicos a partir do código HTML dos websites. Segundo [Mitchell 2018], técnicas de *web scraping* possibilitam coletar dados automaticamente de páginas web para posterior processamento e análise. Essa abordagem é amplamente utilizada na obtenção de dados públicos disponibilizados em portais governamentais da Internet, viabilizando a extração em larga escala e a estruturação de informações que, de outra forma, demandaria um elevado esforço manual.

2.2.2. Web Crawling

O *web crawling* consiste na navegação automatizada entre páginas web por meio de agentes computacionais denominados *crawlers*. Conforme descrito por [Liu and Menczer 2011], essa abordagem permite percorrer *hyperlinks* de forma sistemática, possibilitando a descoberta, coleta e catalogação de informações disponíveis na Web.

Diferentemente do *web scraping*, cujo foco está na extração de conteúdos específicos, o *web crawling* possui como principal objetivo identificar e organizar páginas e recursos distribuídos em diferentes estruturas de navegação, conforme ilustrado na Figura 1.



Figura 1. Diferença conceitual entre os processos de Web Crawling e Web Scraping.
Fonte: Elaborada pela autora.

3. Trabalhos Relacionados

Esta seção apresenta trabalhos relacionados à proposta desta pesquisa, agrupados em três categorias: (i) estudos da literatura científica que exploram diferentes metodologias, aplicações e técnicas de raspagem de dados aplicadas a informações públicas disponibilizadas em portais governamentais; (ii) pesquisas que empregam métodos de *web scraping* para analisar a representatividade feminina em ambientes digitais e científicos; e (iii) pesquisas que abordam as desigualdades enfrentadas por mulheres no espaço urbano e as consequências da ausência da análise de dados sob a perspectiva de gênero para o planejamento das cidades.

Pesquisas recentes têm explorado abordagens para automatizar a extração e a análise de informações em portais de transparência pública. [Pereira and Dorneles 2025] apresentam uma metodologia de automação para mapeamento de dados de licitações públicas em portais de municípios catarinenses, utilizando técnicas de *web scraping* com Python, Selenium e BeautifulSoup. A solução permite a extração estruturada e centralizada de informações antes dispersas, possibilitando análises comparativas em larga escala. Apesar dos desafios, como a falta de padronização dos portais e barreiras técnicas como CAPTCHA¹, os resultados demonstram a viabilidade de abordagens automatizadas para ampliar o acesso a dados públicos. De modo semelhante, [Assis and Gomide 2021] desenvolvem um método de raspagem de dados aplicado aos gastos públicos dos vereadores da Câmara Municipal de Belo Horizonte. Também com Python e bibliotecas como Selenium, BeautifulSoup e Pandas, os autores demonstram como dados desestruturados podem ser transformados em informações abertas e estruturadas, alinhadas à Lei de Acesso à Informação. A pesquisa culmina na criação de um *chatbot* que permite à população consultar os gastos parlamentares mensais, evidenciando o potencial da automação como instrumento de fortalecimento da transparência e da participação cidadã.

Estudos relacionados ao uso da informação de gênero têm aplicado métodos automatizados para analisar desigualdades em ambientes digitais e científicos. [Regueira et al. 2020] analisam a representação feminina no YouTube por meio da técnica de *web scraping*. Utilizando a linguagem R, os autores coletaram dados de cinquenta canais com maior número de seguidores na Espanha e identificaram uma sub-representação significativa de mulheres: apenas quatro criadoras entre os cinquenta canais analisados, nenhuma entre os dez mais populares. A análise do perfil do público desses canais também revelou uma predominância de

¹ CAPTCHA (Completely Automated Public Turing test to tell Computers and Humans Apart) é um mecanismo de segurança utilizado para diferenciar usuários humanos de acessos automatizados, funcionando como uma barreira para procedimentos de web scraping.

audiência masculina (74,1%), reforçando padrões de visibilidade desiguais. De modo complementar, [Santana and Braga 2020] empregam a linguagem Python e bibliotecas como BeautifulSoup, Pandas e Matplotlib para realizar análises quantitativas da produção científica no Congresso da Sociedade Brasileira de Computação entre 2017 e 2019. Os resultados evidenciam uma sub-representação feminina na autoria dos trabalhos, com cerca de 31% de mulheres entre os autores, além de predominância masculina em todas as posições de autoria. Ainda assim, observa-se que as mulheres estão presentes em mais da metade das publicações analisadas, indicando participação relevante, embora ainda desigual, na produção científica da área no período estudado.

No conjunto de trabalhos que evidenciam as consequências da ausência da análise e desagregação dos dados por gênero, destaca-se [Beck 2024], que investiga as desigualdades de mobilidade entre mulheres residentes em Colombo, região Metropolitana de Curitiba. Utilizando o método do Percurso Comentado, a autora evidencia barreiras como calçadas inexistentes, pontos de ônibus precários, insegurança e ausência de integração tarifária entre municípios. Além disso, o artigo ressalta que pesquisas municipais de mobilidade não coletaram dados desagregados por gênero, o que limita a compreensão das reais necessidades das usuárias. Complementarmente, [Araujo et al. 2025] analisam as desigualdades de acessibilidade em Curitiba a partir da interseção entre gênero e renda, utilizando um modelo baseado em agentes e dados da Pesquisa Origem-Destino. Os resultados revelam que mulheres, especialmente as de baixa renda, têm menor acesso a oportunidades urbanas devido à segregação espacial e à dependência do transporte público, reforçando a importância de políticas de mobilidade com enfoque de gênero.

Neste trabalho, o estudo será conduzido por uma abordagem automatizada para o mapeamento de dados públicos em três municípios paranaenses de grande porte. De forma semelhante aos trabalhos de [Pereira and Dorneles 2025] e [Assis and Gomide 2021], utiliza-se o ecossistema tecnológico baseado em Python, Selenium e BeautifulSoup para atuar em portais governamentais. No entanto, diferenciando-se das abordagens focadas em extração em tela, este estudo propõe uma arquitetura baseada em *web crawling* para a descoberta de arquivos de dados, aliada à mineração de metadados. Posteriormente, realiza-se uma curadoria qualitativa dos dados identificados, buscando avaliar seu potencial para subsidiar projetos de planejamento urbano com enfoque de gênero, respondendo às necessidades apontadas por [Beck 2024] e [Araujo et al. 2025].

4. Metodologia

Para alcançar os objetivos propostos, a metodologia foi desenvolvida para coletar, estruturar e analisar dados públicos dos municípios de Curitiba, Londrina e Maringá. A escolha destas três cidades justifica-se por serem os maiores polos urbanos do Paraná, concentrando grandes volumes de informações governamentais.

Devido à quantidade de páginas e à falta de padronização nos portais das prefeituras, a busca manual por documentos com recorte de gênero torna-se um desafio para pesquisadores. Para resolver esse problema, desenvolveu-se uma solução automatizada que combina técnicas de exploração web (*crawling*), extração de metadados dos arquivos (*scraping*) e mineração de dados.

A arquitetura proposta foi dividida em quatro etapas complementares e sequenciais, conforme ilustra a Figura 2.




Figura 2. Representação visual das etapas metodológicas.

Fonte: Elaborada pela autora.

4.1. Etapa 1: *Crawler* (Mapeamento)

O algoritmo de busca do *crawler* inicia a partir de URLs base dos portais das cidades, conhecidos como URLs-semente. Esses links foram escolhidos manualmente e representam o site oficial de cada prefeitura, os portais da transparência e os sistemas de dados abertos, conforme apresentados na Tabela 1.

Tabela 1. Mapeamento das URLs-semente utilizadas como ponto de partida da coleta.

Município	Tipo de Portal	URL-Semente (Ponto de Entrada)
Curitiba	Institucional	https://www.curitiba.pr.gov.br/
	Transparência	https://www.transparencia.curitiba.pr.gov.br/
	Dados Abertos	https://dadosabertos.curitiba.pr.gov.br/
Londrina	Institucional	https://portal.londrina.pr.gov.br/
	Transparência	https://portal.londrina.pr.gov.br/transparencia
	Sistema Terceirizado	https://portal-prefeitura-londrina.equipiano.cloud/inicio
Maringá	Institucional	https://www.maringa.pr.gov.br/
	Sistema Terceirizado	https://maringa.oxy.elotech.com.br/portaltransparencia/1/

Fonte: Elaborada pela autora.

A partir desses pontos de partida listados, inicia-se a varredura focada na descoberta de arquivos públicos. Para que essa navegação ocorra de forma organizada e sem sobrecarregar os servidores governamentais, o algoritmo foi desenhado utilizando a estratégia de Busca em Largura (Breadth-First Search - BFS). Nessa abordagem, o agente computacional explora todos os links da página inicial antes de avançar para os links subsequentes, garantindo que os documentos mais acessíveis para a população sejam mapeados primeiro. Para evitar laços infinitos (comuns em sistemas de calendário), foram implementadas duas travas de segurança: a restrição de profundidade máxima de navegação e a deduplicação inteligente de URLs (remoção de parâmetros dinâmicos de sessão). Para garantir a continuidade em coletas de longa duração, o módulo implementa um sistema de checkpoint que persiste o estado de execução (URLs já visitadas e URLs pendentes na fila) em arquivos no formato JSON, permitindo que a varredura seja pausada e retomada exatamente do ponto onde parou. Adicionalmente, para garantir a es-

tabilidade da execução e evitar o bloqueio por negação de serviço, aplicou-se uma pausa ética de requisição.

Para conseguir acessar páginas protegidas por bloqueios de segurança, o sistema conta com uma estratégia em três níveis. Inicialmente, o *crawler* tenta realizar o acesso direto. Caso seja bloqueado, ele aciona automaticamente a biblioteca Selenium em modo invisível, que emula um navegador real para contornar a barreira. Se um CAPTCHA persistente for detectado, o *crawler* avança para o terceiro nível: uma janela visível é aberta, interrompendo a execução por 60 segundos para permitir a intervenção humana a fim de realizar a resolução manual do desafio. Caso o tempo se esgote sem a ação humana, ocorre o registro na planilha de erros com o status `CAPTCHA_NAO_RESOLVIDO`, garantindo rastreabilidade e transparência sobre quais URLs não puderam ser acessadas automaticamente e prossegue com a varredura das demais. Os artefatos finais desta etapa consistem em uma planilha de inventário, contendo a localização e o tipo dos arquivos públicos descobertos, e uma planilha de erros, que registra os links corrompidos ou inacessíveis para fins de auditoria e transparência metodológica.

4.2. Etapa 2: Downloader (Extração)

A partir do inventário gerado na etapa anterior, o fluxo segue para o módulo *Downloader*. Esta fase tem como objetivo iterar sobre a lista de arquivos descobertos, focando no download de dados abertos estruturados e de formato tabular (com extensões `.xlsx`, `.xls`, `.xslm` e `.ods`), além de arquivos compactados em `.zip` e `.rar` e arquivos de texto `.txt`.

Para lidar com instabilidades na Internet ou lentidão nos sites das prefeituras, o código realiza novas tentativas de acesso de forma automática caso o primeiro download falhe. Todos os arquivos baixados com sucesso são salvos localmente no computador, formando a base de dados bruta que servirá de material para a próxima etapa.

4.3. Etapa 3: Analisador (Mineração)

Nesta etapa, o processo afasta-se da navegação web e entra no domínio da mineração de dados. O módulo Analisador opera em ambiente local, processando o conteúdo interno de cada documento armazenado na base de dados bruta.

Para a identificação da perspectiva de gênero, o Analisador carrega cada arquivo em memória e realiza varreduras em duas camadas: primeiro nos nomes das colunas e, em seguida, no conteúdo de todas as células e linhas do documento. A busca utiliza um dicionário de palavras-chave predefinidas combinado com expressões regulares, evitando falsos positivos por correspondência parcial. O resultado desta etapa é a compilação do relatório detalhado de ocorrências de gênero, contendo os termos detectados em cada arquivo e o registro para a fase de curadoria qualitativa.

4.4. Etapa 4: Curadoria Qualitativa (Análise Humana)

Por fim, reconhecendo que buscas automáticas por palavras-chave estão sujeitas a falsos positivos, a última etapa consiste em uma curadoria qualitativa realizada de forma manual.

Nesta fase, é avaliado o relatório gerado na etapa anterior para verificar se o arquivo apontado pelo algoritmo é, de fato, pertinente ao contexto do planejamento urbano. O objetivo dessa triagem é descartar documentos não relacionados ao tema central e entender de forma crítica como a questão de gênero está sendo tratada nos documentos públicos analisados que realmente importam. Essa análise final é o que forma a base para as conclusões do estudo.

5. Desenvolvimento

Seguindo a metodologia definida, esta seção detalha o processo de desenvolvimento e a execução prática do estudo. Serão apresentadas as tecnologias escolhidas para a construção da ferramenta, as soluções implementadas para garantir a estabilidade do processamento em larga escala, bem como os parâmetros técnicos utilizados durante a varredura dos portais.²

5.1. Tecnologias Utilizadas

A ferramenta de extração foi desenvolvida na linguagem de programação Python, escolhida por sua ampla adoção em projetos de ciência de dados, conforme evidenciado na revisão bibliográfica.

No módulo do Crawler, o acesso às páginas web foi feito utilizando a biblioteca *requests*. Após baixar a página, a biblioteca Beautiful Soup foi usada para ler o código HTML e conseguir extrair os links e dados relacionados às páginas. Para lidar com as páginas que possuíam sistemas de segurança (como proteção contra robôs), foi utilizado o Selenium, o qual funciona abrindo um navegador de forma invisível na memória para tentar contornar os bloqueios.

Por fim, a biblioteca pandas atuou como a ferramenta central de estruturação de dados do sistema. Na Etapa 1, foi usada para consolidar e gerar duas planilhas em formato .xlsx: o inventário dos arquivos encontrados e o registro de erros das páginas não acessadas. Nas Etapas 2 e 3, o pandas voltou a ser essencial para ler o inventário de arquivos como entrada do Downloader, registrar o status de cada download e processar o conteúdo das planilhas baixadas na etapa de mineração.

5.2. Execução em Larga Escala e Protocolos Éticos

A execução do sistema foi realizada em ambiente local. Como a arquitetura orientada a objetos do código isola o estado e os arquivos de salvamento de cada cidade, o processamento dos municípios pôde ser executado de forma paralela e independente em múltiplos terminais. Devido à altíssima volumetria de páginas nos portais governamentais, a extração demandou dezenas de horas de processamento ininterrupto. Ao final da varredura de Curitiba, por exemplo, o arquivo de checkpoint registrou mais de 153.000 URLs inspecionadas, conforme ilustrado na Figura 3.

```
153220 "https://educacao.curitiba.pr.gov.br/conteudo/inscricoes/~unidade/profissionais/",
153221 "https://educacao.curitiba.pr.gov.br/conteudo/censo-escolar/~unidade/educacao/unidade/
153222 "https://educacao.curitiba.pr.gov.br/conteudo/cardapio-escola-municipal-ditmar-brepohl-
153223 "https://legisladoexterno.curitiba.pr.gov.br/VisualizarHTML.aspx?id=3290",
153224 "https://feas.curitiba.pr.gov.br/noticias/ultimas-noticias/175-campanha-ulcera-por-pres
153225 "http://educacao.curitiba.pr.gov.br/conteudo/linhas-do-conhecimento/~unidade/comunidade/
153226 "https://educacao.curitiba.pr.gov.br/conteudo/composicao/~unidade/criancas-e-estudante
153227 "http://legisladoexterno.curitiba.pr.gov.br/VisualizarHTML.aspx?id=140620",
153228 "https://educacao.curitiba.pr.gov.br/eventos/unidade/educacao/~unidade/profissionais/~
153229 "https://educacao.curitiba.pr.gov.br/unidade/vale-creche/~unidade/profissionais/~unid
153230 "https://educacao.curitiba.pr.gov.br/conteudo/reunioes-2026/~unidade/profissionais/uni
153231 "https://educacao.curitiba.pr.gov.br/conteudo/credenciamento/~unidade/links-uteis/unid
153232 ]
```

Figura 3. Trecho final do arquivo de checkpoint da varredura de Curitiba, contendo 153.232 URLs inspecionadas. Fonte: Elaborada pela autora.

²O código-fonte e arquivos de resultados estão disponíveis em: <https://github.com/AdrianaSarturi/tcc-dados-publicos-genero-pr>

Para viabilizar uma execução dessa magnitude sem causar impactos negativos à infraestrutura das prefeituras, protocolos éticos de raspagem foram implementados. O robô foi configurado para injetar um cabeçalho de identificação institucional (*User-Agent*) em todas as requisições, deixando claro o propósito acadêmico do acesso. Adicionalmente, estabeleceu-se um intervalo obrigatório de 1,5 segundos entre cada requisição (`PAUSA_ENTRE_REQUESTS`), garantindo que o mapeamento ocorresse sem gerar negação de serviço (DoS) aos portais públicos, mesmo que isso aumentasse o tempo de coleta.

Adicionalmente, para garantir que a varredura se mantivesse dentro de um escopo de dados genuinamente acessíveis ao cidadão, estabeleceu-se um limite máximo de profundidade de navegação de 10 cliques a partir das URLs-semente. Essa decisão foi fundamentada em testes exploratórios realizados no portal de Maringá, nos quais a remoção do limite expôs um problema recorrente: sistemas de calendários governamentais geravam links infinitos, inviabilizando a varredura. Neste trabalho, considerou-se que documentos localizados a mais de 10 níveis de navegação a partir da página inicial são dados de difícil acesso, pois o próprio conceito de transparência ativa pressupõe que a informação seja facilmente localizável pela população.

5.3. *Download*, Mineração de Dados e Curadoria Qualitativa

A transição da descoberta de links para a análise de conteúdo inicia-se com a Etapa 2 (*Downloader*). Este módulo consome a planilha de inventário gerada pelo *crawler* e realiza o download sequencial dos arquivos. Para garantir o rastreamento da operação, o sistema atualiza dinamicamente uma coluna de status na própria planilha registrando o desfecho técnico de cada requisição, o que permite rastrear quais links foram baixados com sucesso.

Após o armazenamento dos arquivos, a Etapa 3 (*Analizador*) opera de forma totalmente offline. Para automatizar a busca por informações desagregadas por gênero, desenvolveu-se um dicionário de palavras-chave que abrange tanto os termos estruturais diretos (como "gênero", "sexo", "identidade de gênero") quanto os valores mais comuns encontrados nas tabelas (como "feminino", "mulher", "masculino", "homem").

O Analisador percorre o conteúdo integral de cada documento, garantindo que nenhum indicador de gênero seja perdido independentemente da sua posição. Para os compactados nos formatos `.zip` e `.rar`, realiza-se a extração dos arquivos internos elegíveis para uma pasta local e os analisa individualmente pelo mesmo processo. Arquivos `.txt` são inspecionados previamente por *magic bytes*: caso sejam identificados como planilhas com extensão incorreta, são tratados como tal; caso contrário, o conteúdo textual é varrido diretamente em busca dos termos do dicionário.

Ao final da varredura, o Analisador compila um relatório de ocorrências de gênero no formato `.xlsx`, reunindo, para cada arquivo analisado, os metadados identificadores (nome, extensão, URL de origem e caminho relativo), os termos de gênero detectados pela mineração de dados e o número de colunas identificadas. Dado que a detecção automatizada de termos opera sobre padrões léxicos, fez-se necessária uma etapa final de curadoria manual para distinguir ocorrências genuinamente relevantes de falsos positivos. Para isso, foram definidos três critérios de relevância qualitativa, aplicados individualmente a cada arquivo pré-selecionado pelo Analisador:

1. **Pertinência Temática (Urbanística):** Avalia se o arquivo aborda temas de planejamento urbano, infraestrutura de transportes, habitação, segurança urbana, demografia local ou serviços públicos essenciais, inserindo-se no escopo do estudo.
2. **Substantividade do Recorte (Qualidade do Dado):** Verifica se o termo de gênero encontrado constitui uma variável ativa e estrutural da planilha (ex: uma coluna de

sexo utilizada para estratificar dados socioeconômicos) ou se representa apenas um falso positivo técnico (abreviações, nomes próprios ou ruídos de formatação).

3. **Apoio a Políticas Públicas:** Examina se os dados do arquivo têm o potencial de subsidiar, monitorar ou fundamentar políticas municipais voltadas à igualdade, segurança e bem-estar dos cidadãos.

Um arquivo é considerado válido para a pesquisa apenas quando atende aos critérios, assegurando que o conjunto de dados final reflita a presença de informações governamentais abertas com recorte de gênero que sejam realmente relevantes.

Para operacionalizar essa avaliação, o relatório gerado pelo Analisador (`relatorio_genero.xlsx`) inclui três colunas reservadas à curadoria manual: `curadoria_relevancia`, `curadoria_justificativa` e `criterio_atendido`. Os arquivos pré-selecionados automaticamente, ou seja, aqueles em que ao menos um termo de gênero foi detectado, recebem o valor "Aguardando" na primeira coluna, indicando que requerem revisão humana. Após a análise, esse valor foi substituído por "Sim" ou "Não", a justificativa da decisão foi registrada na segunda coluna e o critério qualitativo atendido foi indicado na terceira coluna (para os casos confirmados), tornando o processo auditável, conforme exemplificado na Tabela 2.

Tabela 2. Amostra do relatório de gênero gerado para o município de Curitiba, com as colunas de curadoria qualitativa preenchidas após revisão humana.

nome_arquivo	ext.	tem_recorte_gênero	termos_encontrados	total_colunas	curadoria_relevancia	curadoria_justificativa	criterio_atendido
Programação do...	.xls	Sim	mulher	–	Não	Termo "mulher" em título de palestra, não como variável de gênero. Programação comunitária sem dado analítico.	–
Receita Prevista...	.xls	Sim	mulher, mulheres	14	Sim	Receita orçamentária com categoria específica para programas da mulher.	Apoio a Políticas Públicas
Receita Prevista...	.xls	Sim	mulher, mulheres	10	Sim	Receita orçamentária com categoria específica para programas da mulher.	Apoio a Políticas Públicas
Receita Prevista...	.xls	Sim	mulher, mulheres	10	Sim	Receita orçamentária com categoria específica para programas da mulher.	Apoio a Políticas Públicas
Orçamento do Cr...	.xlsx	Sim	mulheres	36	Sim	Orçamento com valores alocados a programas cujo público-alvo inclui mulheres.	Apoio a Políticas Públicas
Lista-SMOP-Excel...	.xlsx	Sim	homem	5	Não	Falso positivo. Termo "homem" é sobrenome de funcionário (Wesley Andrade Homem), não campo de gênero.	–
Lista-SGM-Excel...	.xlsx	Sim	homem	3	Não	Falso positivo. Termo "homem" aparece no nome da unidade de lotação (Casa da Mulher Brasileira), não como campo de gênero.	–

Fonte: Elaborada pela autora.

5.4. Limitações Técnicas

A primeira limitação refere-se ao uso de tecnologias de renderização dinâmica baseadas em JavaScript, como no portal terceirizado da Elotech. Nesses ambientes, o conteúdo das páginas é gerado dinamicamente no navegador do cliente, tornando-o invisível para robôs que operam sobre o HTML estático, evidenciando como portais terceirizados impõem desafios à abordagem de descoberta automática adotada neste trabalho, que depende da análise do código-fonte inicial das páginas para identificar e catalogar recursos disponíveis.

No nível dos arquivos, identificaram-se duas limitações: a presença de documentos protegidos por senha ou corrompidos, que a biblioteca Pandas não consegue ler, impossibilitando a mineração automatizada; e arquivos distribuídos com extensão `.txt` que eram, na prática, planilhas excel identificáveis pelos *magic bytes* PK, exigindo uma camada adicional de inspeção no Analisador.

Quanto às barreiras de acesso, o uso de CAPTCHA como mecanismo de proteção contra robôs foi identificado em portais governamentais, com ocorrências registradas na planilha de erros ou tratadas por meio de intervenção humana. Adicionalmente, o subdomínio

`pref.londrina.pr.gov.br` encontrava-se desativado, porém ainda resolvia via DNS retornando HTTP 404 em todas as ≈ 26.000 URLs; identificado na varredura-piloto, foi explicitamente excluído da configuração antes da coleta oficial, uma vez que sua inclusão geraria um volume expressivo de erros sem nenhum dado recuperável. Por fim, o portal de Curitiba ativou um mecanismo de bloqueio de IP na profundidade 10 da varredura, após volume elevado de requisições, exigindo a alternância de redes para a conclusão da coleta e dos downloads.

6. Resultados e Discussões

A Tabela 3 apresenta um resumo geral da coleta nos três municípios, com o total de páginas visitadas, a profundidade máxima configurada, o último nível em que foram encontrados arquivos, a quantidade de arquivos descobertos e os erros de acesso registrados. O algoritmo de varredura foi configurado com profundidade máxima de 10 níveis para todos os portais e executou a varredura completa até esse limite em todas as execuções; contudo, a distribuição dos arquivos encontrados variou significativamente: Maringá esgotou seus arquivos úteis já no nível 5, Curitiba os registrou até o nível 9, enquanto Londrina apresentou documentos distribuídos até o limite máximo configurado. Esse resultado evidencia que cada portal municipal organiza e disponibiliza seus dados públicos em estruturas de profundidade e volumes distintos. Os resultados refletem exclusivamente os dados acessíveis a partir das URLs-semente definidas (Seção 4.1), não contemplando fontes externas como APIs governamentais ou bases do SUS.

Tabela 3. Panorama geral da coleta por município.

Município	Páginas Visitadas	Profundidade Configurada	Último Nível com Arquivos	Arquivos Encontrados	Erros Registrados
Maringá	8.821	10	5	13.340	174
Londrina	141.768	10	10	43.030	5.549
Curitiba	153.230	10	9	73.173	1.162

Fonte: Elaborada pela autora.

Para ilustrar a estruturação desses dados, as Tabelas 4 e 5 apresentam amostras das planilhas geradas ao final de cada varredura. O inventário de links (Tabela 4) consolida o mapeamento dos arquivos válidos encontrados, registrando metadados como URL, extensão e profundidade da página. A planilha de erros (Tabela 5) atua como um registro de auditoria, documentando links inacessíveis, páginas não encontradas e bloqueios de servidor. Nota-se também o registro do status HTTP 0, que evidencia a resiliência do algoritmo ao capturar quedas abruptas de conexão sem interromper o fluxo principal da coleta.

Tabela 4. Amostra da planilha de inventário gerada para o município de Londrina, detalhando os metadados dos arquivos públicos encontrados.

cidade	url_encontrada	dominio_encontrado	texto_no_site	pagina_de_origem	tipo_arquivo	profundidade	status_http	data_varredura
Londrina	https://portal.lo...	portal.londrina.pr.gov	Jornal-5766...	https://portal.londr...	.pdf	1	200	2026-05-11 17:25:28
Londrina	https://portal.lo...	portal.londrina.pr.gov	Jornal-5765...	https://portal.londr...	.pdf	1	200	2026-05-11 17:25:28
Londrina	https://portal.lo...	portal.londrina.pr.gov	Jornal-5764...	https://portal.londr...	.pdf	1	200	2026-05-11 17:25:28
Londrina	https://portal.lo...	portal.londrina.pr.gov	Jornal-5763...	https://portal.londr...	.pdf	1	200	2026-05-11 17:25:29
Londrina	https://portal.lo...	portal.londrina.pr.gov	Jornal-5762...	https://portal.londr...	.pdf	1	200	2026-05-11 17:25:29
Londrina	https://portal.lo...	portal.londrina.pr.gov	Jornal-5761...	https://portal.londr...	.pdf	1	200	2026-05-11 17:25:29
Londrina	https://portal.lo...	portal.londrina.pr.gov	Jornal-5760...	https://portal.londr...	.pdf	1	200	2026-05-11 17:25:29
Londrina	https://portal.lo...	portal.londrina.pr.gov	Jornal-5759...	https://portal.londr...	.pdf	1	200	2026-05-11 17:25:29
Londrina	http://www1.lor...	www1.londrina.pr.gov.br	–	https://portal.londr...	.pdf	1	200	2026-05-11 17:26:05
Londrina	https://portal.lo...	portal.londrina.pr.gov	Decreto 496...	https://portal.londr...	.pdf	1	200	2026-05-11 17:26:05
Londrina	https://portal.lo...	portal.londrina.pr.gov	Suspenso...	https://portal.londr...	.pdf	1	200	2026-05-11 17:26:24
Londrina	http://www2.lor...	www2.londrina.pr.gov	Decreto 1073...	https://portal.londr...	.pdf	1	200	2026-05-11 17:26:45
Londrina	http://www2.lor...	www2.londrina.pr.gov	http://www2...	https://portal.londr...	.pdf	1	200	2026-05-11 17:27:09
Londrina	http://www1.lor...	www1.londrina.pr.gov	http://www1...	https://portal.londr...	.pdf	1	200	2026-05-11 17:27:09
Londrina	https://portal.lo...	portal.londrina.pr.gov	https://portal...	https://portal.londr...	.pdf	1	200	2026-05-11 17:27:09

Fonte: Elaborada pela autora.

Tabela 5. Amostra da planilha de registro de erros de varredura do município de Maringá, utilizada para auditoria técnica de links inacessíveis.

cidade	url_bloqueada	tipo_erro	status_http	data_hora
Maringá	http://www3.m...	HTTP_500	500	2026-05-16 23:15:46
Maringá	https://maringa...	HTTP_404	404	2026-05-16 23:36:27
Maringá	https://telefone...	TIMEOUT_OU_CONEXAO	0	2026-05-16 23:43:31
Maringá	https://telefone...	SELENIUM_ERRO: WebDriverException	0	2026-05-16 23:43:33
Maringá	http://www.ma...	HTTP_404	404	2026-05-16 23:58:05
Maringá	https://www3.r...	HTTP_404	404	2026-05-17 00:11:52
Maringá	http://www.ma...	TIMEOUT_OU_CONEXAO	0	2026-05-17 00:48:09
Maringá	http://www.ma...	SELENIUM_ERRO: WebDriverException	0	2026-05-17 00:48:12
Maringá	https://www.m...	HTTP_404	404	2026-05-17 03:18:12
Maringá	https://www.m...	HTTP_404	404	2026-05-17 03:18:14

Fonte: Elaborada pela autora.

A análise das planilhas de erros revelou dados importantes sobre a infraestrutura das coletas e a viabilidade de soluções automatizadas para raspagem de dados públicos municipais. Os erros HTTP 404 representaram 40,2% do total de erros registrados (2.765 de 6.885), com concentração especialmente elevada em Maringá, onde corresponderam a 94,3% dos erros locais, indicando grande quantidade de documentos movidos ou excluídos sem atualização das páginas. Em Londrina, os erros HTTP 404 também predominaram (45,5% dos erros locais), porém com distribuição mais heterogênea, incluindo falhas de servidor HTTP 500 (20,8%) e timeouts (17,9%). Curitiba apresentou perfil distinto: 81,8% dos erros foram falhas de conexão e timeout, comportamento consistente com as restrições de acesso impostas pelo servidor durante a varredura, conforme discutido na Subseção de Limitações Técnicas. Ainda assim, a abordagem automatizada demonstrou-se viável: o método varreu mais de 303 mil páginas de forma autônoma, sendo as barreiras encontradas limitações estruturais dos próprios portais, devidamente registradas nas planilhas de auditoria.

Ao isolar apenas os links válidos que apontavam para documentos, foi possível categorizar os arquivos encontrados. A Tabela 6 mostra a distribuição dos arquivos por tipo de extensão. Observa-se a predominância do grupo Documentos, composto majoritariamente por arquivos PDF, em contraste com formatos de dados (como planilhas XLS e XLSX). Isso é um resultado esperado, evidenciando a divulgação de documentos públicos nesses portais.

Tabela 6. Distribuição dos arquivos coletados por grupo e município.

Grupo	Extensões	Maringá	Londrina	Curitiba
Planilhas	.xls, .xlsx, .xlsm, .ods	20	2.972	316
Documentos	.pdf, .doc, .docx, .docm, .odt, .rtf, .txt	13.070	39.168	61.809
Apresentações	.ppt, .pptx, .ppsx	0	53	21
Geoespaciais	.dwg, .kmz	44	16	0
Outros	.ashx, .pyz, .vcf, .xml, .cdr, .exe, .p7b	0	18	11.013
Total		13.134	42.227	73.159

Fonte: Elaborada pela autora.

* Os arquivos compactados (.zip, .rar) tiveram seus conteúdos extraídos pelo Analisador, sendo os arquivos de formato elegível (.xlsx, .xls, .xlsm, .ods, .txt) contabilizados em suas respectivas categorias.

O total da Tabela 6 é ligeiramente menor que o total registrado na Tabela 3, pois foram desconsideradas nesta distribuição as ocorrências com extensões malformadas, como `.pdf]`, `.html> e .url}}`. Essas anomalias são geradas por erros de programação nos próprios portais governamentais e não representam arquivos acessíveis.

A Etapa 3 foi aplicada sobre o conjunto de arquivos efetivamente baixados pela Etapa 2. Portanto, a coluna “Arquivos Analisados” da Tabela 7 corresponde ao total de arquivos físicos salvos com sucesso no disco para cada município. Esse total é consideravelmente menor que a soma de links observada na Tabela 6 por três fatores: primeiro, pelo descarte automático de formatos não considerados para a coleta; segundo, pela indisponibilidade técnica nos portais, como links quebrados ou restrições de servidor; terceiro, pela deduplicação de conteúdo, feita calculando um hash MD5 representativo de cada arquivo baixado e removendo cópias idênticas geradas por URLs distintas que apontavam para o mesmo recurso no servidor — situação recorrente em portais que referenciam o mesmo arquivo tanto via protocolo HTTP quanto HTTPS. A Tabela 7 sintetiza os resultados dos arquivos recuperados com sucesso e sem duplicatas.

Tabela 7. Arquivos com ocorrência de termos de gênero por município.

Município	Arquivos Analisados	Volume Baixado (MB)	Com termos de gênero	Proporção (%)
Maringá	284	2.413	8	2,82%
Londrina	1.669	3.431	612	36,67%
Curitiba	543	121	33	6,08%

Fonte: Elaborada pela autora.

Com base nos arquivos com ocorrência de termos de gênero identificados na Tabela 7, a análise manual foi aplicada para remover falsos positivos. A Tabela 8 consolida o quantitativo final de documentos que, após essa curadoria, foram confirmados como pertinentes e metodologicamente válidos para a pesquisa. Os critérios de relevância qualitativa atendidos por cada documento confirmado, bem como a justificativa individual de inclusão ou exclusão, estão registrados, respectivamente, nas colunas `criterio_atendido` e `curadoria_justificativa` do relatório de gênero disponível no repositório do projeto.

Tabela 8. Documentos confirmados como relevantes após curadoria qualitativa.

Município	Com termos de gênero	Confirmados relevantes	Aproveitamento (%)*
Maringá	8	1	0,35%
Londrina	612	7	0,42%
Curitiba	33	9	1,66%

Fonte: Elaborada pela autora.

* Aproveitamento calculado sobre o total de arquivos analisados por município (Tabela 7).

Os resultados obtidos revelam que dados públicos com recorte de gênero são disponibilizados de forma muito limitada na amostra coletada dos portais municipais analisados. Dos 2.496 arquivos elegíveis coletados e analisados automaticamente pelo Analisador, apenas 653 apresentaram ocorrência de pelo menos um termo do dicionário de gênero e, após curadoria manual para remoção de falsos positivos, apenas 17 documentos foram confirmados como metodologicamente pertinentes, distribuídos entre os três municípios.

No que diz respeito à detecção de gênero, Londrina apresentou a maior proporção de arquivos com termos detectados (36,67%), porém com baixo aproveitamento após curadoria

(0,42%). Essa aparente contradição é explicada pela composição do acervo: a grande maioria dos falsos positivos de Londrina originou-se de planilhas de compras públicas e licitações de medicamentos e produtos hospitalares, cujos nomes comerciais contêm os termos “feminino” e “masculino”, sem qualquer relação com variáveis de gênero em nível individual, evidenciando a necessidade da curadoria manual.

Quanto ao perfil dos conjuntos de dados confirmados, observou-se uma distinção qualitativa relevante entre os municípios. Em Maringá e Londrina, os arquivos confirmados correspondem a microdados individuais com variável de gênero explícita: o Banco de Dados Origem-Destino de Maringá registra o gênero de entrevistados em uma pesquisa de mobilidade urbana com 8.731 registros, atributos como bairro, faixa etária, origem, destino e modo de transporte, e 16% de valores ausentes na coluna de gênero; enquanto Londrina disponibiliza planilhas de parcerias formalizadas com campo de gênero (M, F, com 2,6% de valores ausentes), além de bases do Conselho Municipal dos Direitos da Criança e do Adolescente (CMDCA) e de pesquisa domiciliar do Instituto de Pesquisa e Planejamento Urbano de Londrina (IPPUL). Em todos esses microdados, a variável de gênero é representada de forma binária (Masculino/Feminino), sem categorias não-binárias. Em Curitiba, por outro lado, os dados confirmados são predominantemente de natureza orçamentária, com receitas previstas e despesas fixadas com dotações para o Fundo Municipal da Mulher e programas de políticas públicas voltados ao público feminino. Embora esses dados evidenciem a existência de ações municipais com recorte de gênero, não constituem microdados individuais, mas sim registros agregados de alocação de recursos.

Essa distinção entre microdados e dados orçamentários com recorte de gênero é relevante do ponto de vista metodológico: enquanto os primeiros permitem análises sobre desigualdades de gênero em nível individual, os segundos apenas indicam a existência de programas governamentais dirigidos a esse recorte, sem revelar dados individuais sobre os beneficiários. O resultado desta pesquisa sugere que, nos portais municipais analisados, a transparência de dados com perspectiva de gênero ainda é limitada, restrita a iniciativas pontuais e não padronizadas entre os municípios. Esse cenário é especialmente relevante por se tratar das três maiores cidades do Paraná, onde a escassez de dados estruturados com recorte de gênero, seja pela não coleta, seja pela não divulgação, dificulta tanto a produção de estudos sobre desigualdades de gênero quanto o planejamento urbano com perspectiva igualitária.

7. Conclusão

Este trabalho apresentou uma abordagem automatizada com curadoria humana para coletar e investigar a presença de dados desagregados por gênero nos portais municipais de Curitiba, Londrina e Maringá, demonstrando viabilidade técnica para operar em larga escala com mecanismos de checkpoint. Os resultados evidenciaram a escassez de dados abertos com recorte de gênero na amostra coletada: após a varredura de mais de 303 mil páginas e a análise de 2.496 arquivos elegíveis, apenas 17 documentos foram confirmados como metodologicamente pertinentes, sendo parte deles microdados individuais e parte registros orçamentários com programas voltados ao público feminino. As barreiras técnicas identificadas, como bloqueios por IP e subdomínios desativados, refletem limitações estruturais na disponibilização efetiva de dados abertos pelo poder público.

Como trabalhos futuros, sugere-se a ampliação do escopo para outros municípios e estados do Brasil, permitindo uma visão mais abrangente e comparativa sobre a disponibilização de dados com recorte de gênero na esfera pública. O desenvolvimento de estratégias para lidar com portais baseados em JavaScript, como a utilização de navegadores automatizados durante a própria etapa de varredura, representaria um avanço significativo na cobertura da coleta, su-

perando uma das barreiras identificadas. Adicionalmente, a avaliação de APIs públicas disponibilizadas pelos portais governamentais e outras formas alternativas de obtenção de dados representa uma oportunidade para ampliar e diversificar as fontes de coleta, complementando a abordagem de web scraping e web crawling adotada. Por fim, o uso de inteligência artificial para auxiliar na etapa de curadoria qualitativa representa uma direção promissora, com potencial para reduzir a necessidade de revisão humana e tornar o processo escalável para volumes maiores de dados.

Referências

- [Araujo et al. 2025] Araujo, A. S. d., Massucheto, J., Bugs, G. T., Saraiva, M. V. P., and Duarte, F. (2025). Unveiling inequalities: The intersection of gender and income in accessibility in curitiba, brazil. *Journal of Transport Geography*, 123:104136.
- [Assis and Gomide 2021] Assis, W. V. d. and Gomide, J. V. B. (2021). Web scraping em dados públicos: método para extração de dados dos gastos públicos dos vereadores da câmara municipal de belo horizonte. *Informação amp; Informação*, 26(4):319–341.
- [Beck 2024] Beck, M. P. (2024). As mulheres da metrópole de curitiba e a mobilidade em colombo: Desafios e perspectivas para as trabalhadoras da região metropolitana de curitiba. In *XVI Seminario Internacional de Investigación en Urbanismo (SIU 2024)*, Córdoba, Argentina. Universitat Politècnica de Catalunya.
- [Brasil 2011] Brasil (2011). Lei nº 12.527, de 18 de novembro de 2011. https://www.planalto.gov.br/ccivil_03/_ato2011-2014/2011/lei/l12527.htm. Acesso em: 12 maio 2026.
- [Criado Perez 2022] Criado Perez, C. (2022). *Mulheres invisíveis: o viés dos dados em um mundo projetado para homens*. Editora Intrínseca, Rio de Janeiro. Tradução de Dorothée de Bruchard.
- [Freitas and Praça 2024] Freitas, M. N. d. and Praça, S. R. M. (2024). Transparência sobre dirigentes públicos estaduais: uma análise exploratória. *Cadernos Gestão Pública e Cidadania*, 29:e89150.
- [Han et al. 2012] Han, J., Kamber, M., and Pei, J. (2012). *Data Mining: Concepts and Techniques*. Morgan Kaufmann, San Francisco, 3 edition.
- [Hannas et al. 2024] Hannas, A. S. C. D., Moreira, G. C., and Cruz, A. C. d. (2024). Mobilidade urbana e desigualdades de gênero na cidade de são paulo. *urbe. Revista Brasileira de Gestão Urbana*, 16:e20230141.
- [Lefebvre 2004] Lefebvre, H. (2004). *O direito à cidade*. Centauro, São Paulo, 5 edition.
- [Liu and Menczer 2011] Liu, B. and Menczer, F. (2011). *Web Crawling*, pages 311–362. Springer.
- [Mitchell 2018] Mitchell, R. (2018). *Web Scraping with Python: Collecting More Data from the Modern Web*. O'Reilly Media.
- [Pereira and Rebelo 2024] Pereira, A. and Rebelo, E. M. (2024). Women in public spaces: Perceptions and initiatives to promote gender equality. *Cities*, 154:105346.
- [Pereira and Dorneles 2025] Pereira, B. and Dorneles, C. (2025). Uma metodologia para coleta e mapeamento de dados de licitações públicas dos portais da transparência dos municípios de santa catarina. In *Anais da XX Escola Regional de Banco de Dados*, pages 50–59, Porto Alegre, RS, Brasil. SBC.
- [PNUD et al. 2022] PNUD, Arup, and University of Liverpool (2022). *Cities alive: Designing cities that work for women*.

- [Regueira et al. 2020] Regueira, U., Alonso Ferreiro, A., and Da-Vila, S. (2020). Women on youtube: Representation and participation through the web scraping technique. *Comunicar*, 63.
- [Santana and Braga 2020] Santana, T. and Braga, A. (2020). Uma análise cienciométrica das publicações do congresso da sociedade brasileira de computação na perspectiva das mulheres na computação. In *Anais do XIV Women in Information Technology*, pages 279–283, Porto Alegre, RS, Brasil. SBC.